

HumanEgo: 从数分钟的人类第一人称视频实现零样本机器人学习

智 (利奥) 王

高若涵

黄福荣 阿洛伊莫

马里兰大学

李胜幸


<https://humanego-ai.github.io/>

图1: HumanEgo 从人类第一人称视频中学习机器人策略。一名人类佩戴 Aria 眼镜并收集演示 (左) ; 将第一人称视频转换为以交互为中心的表征, 并用于训练流匹配策略 (中) ; 该策略在不依赖环境、部署流程或实体形态的情况下实现零样本迁移到机器人 (右)。

摘要: 人类第一人称视频能够在不需要任何机器人硬件的情况下捕捉丰富的操作演示, 但将这些能力迁移到机器人仍具有挑战性, 这是因为人类与机器人之间存在“实体差距”, 体现在视觉外观和运动学两方面。我们提出 HumanEgo, 这是一个桥接实体差距的框架: 将每个人类演示提升为手-物体交互的实体级表征, 并训练一种流匹配策略, 配合密集的辅助目标, 从每一条轨迹中强化监督。

HumanEgo 不依赖机器人数据、对硬件无关、数据高效, 并实现人类到机器人的零样本可迁移。每个任务只需每人类视频 30 分钟, HumanEgo 在四个真实世界任务上达到 92.5% 的平均成功率 (仅用 15 分钟为 75%), 优于匹配耗时的机器人远程操作 41%, 并能在全新机器人、摄像头和环境之间稳健地进行零样本迁移。我们将 HumanEgo 作为易于使用的开源框架发布: 可直接从人类数据学习机器人策略: <https://github.com/TX-Leo/HumanEgo>。

1 引言

最先进的操作策略需要数百到数千个针对特定任务的机器人演示 [1, 2, 3, 4, 5, 6], 代价高、耗时长且收集不便。人类第一人称视频提供了更廉价且更易获得的替代方案: 借助头戴式摄像机 [7], 单人可以在任意地点、仅需几分钟收集任务演示。但我们应如何利用这些数据? 现有方法主要分为两类范式, 各自都有显著局限。共同训练方法 [8, 9, 10, 11] 用人类视频补充机器人数据, 但对每个新任务仍需要大量机器人演示——这并未消除数据负担, 只是对其有所缓解。大规模预训练方法 [12, 13, 14, 15] 能从海量第一人称数据中学习, 但需要巨大的计算量, 且仍需针对机器人进行特定的后训练, 才能得到可部署的策略。我们追求一个更直接的目标: 仅凭几分钟的人类第一人称演示 (不使用任何机器人数据, 也不进行互联网规模的预训练) 学习可部署的操作策略。

要实现这一目标, 会暴露出两个根本挑战。(1) 表征挑战: 桥接实体差距。人类与机器人在视觉外观和运动学上都存在差异, 而

这些差距要求采用不同的解决方案。在视觉方面，基于重定目标的方法 [16, 17, 18] 能从人类视频合成类似机器人的影像，但对形态学差异和视角差异很脆弱；点跟踪方法 [19, 20, 21] 能提取稀疏几何特征，却丢弃围绕交互的丰富视觉上下文。在运动学方面，层级方法 [22, 23, 24] 将高层计划与低层执行分离，但仍需要机器人数据来训练低层控制器；以物体为中心的方法 [25, 26, 27] 只跟踪被操作的物体，因而丢失关键信息：手是如何接近、如何抓取以及如何释放。我们认为，仅靠“手”或“物体”都无法定义一种技能——真正重要的是它们之间的交互。这正是 HumanEgo 背后的关键表征主张：机器人不应模仿人类身体，而应恢复与任务相关、能够跨越不同身体形态迁移的交互几何。

(2) 学习挑战：从最少数据中学习。尽管原始的人类视频在网上十分丰富，但带有精确动作标签的干净片段仍然稀缺，因此需要在每任务仅有几分钟视频的条件下实现数据高效学习。该范式带来两个截然不同的挑战：多模态与信号稀疏。对于多模态挑战，同一任务允许许多有效策略。基于扩散的方法 [3] 能捕捉该分布，但需要大量去噪步骤且推理很慢；更快的替代方案 [28] 表达能力更弱。对于信号稀疏挑战，每条轨迹都携带除手部动作-物体运动之外更丰富的信号，包括视觉线索、手-物体状态——但已有工作仅挖掘了其中一小部分：例如单一辅助目标，如视觉预见 [25, 29, 30] 或二维轨迹 [19, 27, 31]，或上游预训练语料 [12, 13, 32]。我们认为，将快速生成策略与多类型的密集监督结合，是从人类视角视频的几分钟中实现数据高效学习的关键。换句话说，目标是从人类视频中榨取多种形式的监督，让小规模的精心挑选演示发挥出远超其规模的效果。

我们提出 HumanEgo，通过有针对性的设计来弥补每个缺口。对于视觉缺口，我们对每个以人视角拍摄的画面中的人臂进行修补（in-paint），并在其位置渲染一个带有被跟踪物体关键点的虚拟夹爪，从而得到与具身无关的视觉观测。对于运动学缺口，我们将每只手和每个物体都编码为交互中心标记（Interaction-Centric Token, ICT），从而得到紧凑的、与具身和视角无关的手-物体交互空间观测。对于多模态，我们采用流匹配（flow matching）[33] 策略，在快速推理时生成富有表达力的多模态动作。对于信号稀疏，我们设计三个密集辅助目标：二维轨迹、物体运动以及潜在一致性。它们共同从每条轨迹的场景动力学中产生多类型密集监督，从而提升少量演示下的学习。我们的贡献：

- HumanEgo：一种无需机器人数据（robot-data-free）、与硬件无关（hardware-agnostic）且数据高效的数据处理流程（pipeline），通过可迁移的交互表征与带密集辅助目标的流匹配策略，从原始的人类第一人称（egocentric）视频的几分钟中学习机器人操作策略。
- 交互中心标记（Interaction-Centric Tokens, ICT）：一种紧凑的实体级表示，用于刻画手-物体交互，并且不受具身、视角和环境影响。
- 可靠的零样本（zero-shot）人到机器人迁移。HumanEgo 在每个任务上使用 30 分钟的人类视频训练，能够在 4 个真实世界任务上达到 92.5% 的成功率，并且在将该预算减半的情况下仍达到 75%。在收集时间匹配的条件下，它的表现比机器人远程操控（teleoperation）高出 41%。学习到的策略还能无需训练或微调就对新的机器人具身、相机设置、照明条件、背景以及物体实例进行零样本部署。这表明人类视频并不仅仅是一个便宜的替代品，而是可扩展且可能更优的数据来源，用于策略学习。

2 相关工作

近年来，已经产生了丰富的大规模第一人称（egocentric）以及手-物体交互数据集 [34, 35, 15, 36, 37, 38, 39, 14]，为从人类视频中学习操作提供了数据基础。在此基础上，一类工作扩展通用型策略与世界模型 [12, 13, 40, 41, 42]，从海量语料中学习具身无关的表征；然而部署需要巨大的计算资源，以及针对每个任务的机器人后训练。另一类工作在成对的人类与机器人数据上联合训练 [8, 9, 26, 43, 10, 44, 11]，通过跨具身联合优化来摊销人类信号，但每个新任务仍然需要其自身一批机器人演示。视觉重定向（visual retargeting）方法 [16, 23, 17, 18] 通过对人臂进行修补并在其位置渲染机器人来合成伪机器人演示，但渲染出来的图像对




图2: HumanEgo 的系统概览。手臂修补 (arm inpainting) 与视觉关键点 (visual keypoints) 弥合视觉缺口; 交互中心标记 (Interaction-Centric Tokens) 编码所有实体之间的空间关系; 结合带密集辅助目标的流匹配策略, 可从量级为“分钟”的人类数据中学习双臂机器人动作。

形态与视角变化。分层方法 [22, 24, 45] 从人类视频学习高层计划, 并将低层控制委托给由机器人训练的控制, 但低层技能仍依赖机器人数据。为完全避免机器人数据, 第三类方法追求与形态无关的表示, 以实现零样本迁移; 它们在所表示的内容上有所不同: 基于点的方法 [21, 20, 46, 47] 将场景编码为二维或三维点, 并获得计算效率, 但失去了手与物体之间的结构关系; 以物体为中心的方法 [48, 49, 31, 29, 50] 通过物体的6自由度 (6-DoF) 位姿或运动来表示场景, 能够捕捉物体动力学, 但仅以隐式方式对机械臂进行建模; 而目标条件方法 [19, 51] 根据目标图像预测二维轨迹或三维腕部轨迹, 但在部署时需要明确给定目标。还有若干其他方向 [52, 25, 53, 30, 54, 55, 56, 57] 也在从视频中学习操控, 沿着互补的维度进行探索。这些零样本思路贯穿的一条共同线索是: 它们表示手或物体, 却很少表示二者的交互——也就是定义操控的关键信号。HumanEgo 通过一种以交互为中心的表示来弥合这一差距: 它显式编码手与物体之间的空间关系, 仅需几分钟的人类第一视角视频, 就能实现零样本迁移, 而无需任何机器人数据或大规模预训练。

3 HumanEgo

HumanEgo 将人的第一视角视频转化为可部署的双臂策略, 并分四个阶段完成 (图2)。演示者佩戴 Aria 眼镜记录任务 (第3.1节); 我们通过对人臂进行补全并渲染虚拟夹爪来消除形态差距 (第3.2节), 同时通过将每个实体的位姿相对于其他任务实体编码到交互中心令牌 (Interaction-Centric Tokens) 中 (第3.3节)。通过一个带三个辅助目标的流匹配策略生成多模态双臂动作 (第3.4节)。

3.1 第一视角数据采集

佩戴 Aria Gen1 眼镜的人工演示者 [7] 在任何方便的环境中执行目标任务——不受桌面高度、光照或背景影响——也不需要专门的工作空间或标定 (图11; 附录A)。每次演示只需几秒; 我们在每个任务上收集约 30 Hz 分钟的人类演示。Aria 眼镜特别适合从人类视频中学习: 其机器感知服务 (Machine Perception Services, MPS) 提供高质量的6自由度 (6-DoF) SLAM 跟踪、标定的三维手部位姿估计, 以及同步的第一视角 RGB 流——全部来自一台轻量级可穿戴设备。

3.2 视觉观察预处理

我们以两个步骤将校正后的第一视角帧转换为与形态无关的 RGB 观察。首先，使用 SAM2 分割出人的手和手臂，并通过 LaMa 补全将其移除 [58]，从而消除视觉形态差距。其次，将虚拟夹爪和已跟踪的物体关键点渲染到补全后的图像中——二者都来自空间观察（第3.3节）——从视觉线索中隐式编码6D位姿信息。这个轻量化流程在无需昂贵的领域适配或图像转换的情况下，桥接了视觉形态差距。

3.3 空间观察预处理

我们构建显式的实体级空间观察：将每个物体和双手都视为实体，我们跟踪手与物体以恢复每个实体的6自由度位姿，然后将它们之间的相对关系编码到交互中心令牌中。下面我们详细说明这三个步骤：

手部跟踪与运动优化。我们从 Aria MPS [7] 生成的 3D 手部关键点出发，通过 SLAM 将其提升到世界坐标系，并在位置上使用 Savitzky-Golay 平滑、在旋转上使用指数滑动平均（EMA）平滑。随后，我们将拇指-食指对视为一个虚拟平行夹爪（图 12），提取一个 SE(3) 末端执行器位姿 T_{ee} 和一个标量抓取值 g 。对于位置，我们取指尖中点 $\mathbf{p}_{ee} = (\mathbf{p}_{\text{thumb}} + \mathbf{p}_{\text{index}})/2$ 。对于方向，我们在掌指关节（MCP）上构建 Gram-Schmidt 坐标系，而不是在指尖上， $R_{ee} = \text{GramSchmidt}(\mathbf{x} : \text{拇指 MCP} \rightarrow \text{食指 MCP}, \mathbf{y} : \text{手腕} \rightarrow \text{MCP 中点})$ ，其中 MCP 中点是两个 MCP 的中点；这避免了在抓取时指尖接近时出现的退化。对于抓取值，我们通过对拇指-食指指尖距离归一化来计算一个标量 $g \in [0, 1]$ （详见附录 B.3），并在部署时二值化。

物体跟踪与位姿估计。我们使用文本提示的 Grounding DINO [59] 检测每个物体，用 SAM2 [60] 进行分割，并从掩码中采样轮廓关键点。我们使用 CoTracker3 [61] 在视频中跟踪这些 2D 关键点 $\mathbf{u}_n$ ，并通过 $\mathbf{p}_n = \text{三角化}(\mathbf{u}_n, K, T_{\text{SLAM}})$ 将其提升到 3D，使用相机内参 K 和逐帧的 Aria SLAM 位姿 T_{SLAM} 。我们取 N 个被跟踪点的质心作为物体位置，以抵消逐点三角化噪声，

$\mathbf{p}_{\text{obj}} = \frac{1}{N} \sum_{n=1}^N \mathbf{p}_n$ ，并使用 Orient-Anything V2 [62] 估计方向 R_{obj} 。在抓取过程中，物体会被手

遮挡，因此我们应用运动学锁定——从抓取开始时起将物体位姿刚性绑定到手上

$$t_0 : T_{\text{obj}}^t = T_{\text{hand}}^t \cdot (T_{\text{hand}}^{t_0})^{-1} T_{\text{obj}}^{t_0}。$$

通过交互中心 token（ICT）进行实体空间编码。我们将每个实体的 6-DoF 位姿编码为一个 ICT，同时捕捉其在共享参考系中的位姿以及与双手的空间关系。对于每个实体 $k = 1, \dots, N$ ，其 token $\text{ICT}_k \in \mathbb{R}^{29}$ 为：

$$\text{ICT}_k = [\underbrace{\tau}_1 \parallel \underbrace{{}^{\text{REF}}T_E}_9 \parallel \underbrace{{}^ET_{LH}}_9 \parallel \underbrace{{}^ET_{RH}}_9 \parallel \underbrace{g}_1]， \quad (1)$$

其中 τ 是实体类型（手或物体）； ${}^{\text{REF}}T_E$ 是实体 k 在共享参考系 REF（一个静态相机坐标系）中的姿态； ${}^ET_{LH}$ 和 ${}^ET_{RH}$ 分别是左手（LH）和右手（RH）在实体 k 局部坐标系 E 中的姿态； g 是抓取状态（手为二值化的手指距离；物体为哨兵值）。我们将每个 SE(3) 变换通过拼接归一化平移与 6D 旋转表示 [63] 展平成 9 维向量，并且无需真实标签，直接从现成感知中导出所有量。不同于先前使用全局点云或绝对坐标 [21, 20] 的方法，我们将每个 ICT 锚定到一个实体上，使演化中的 ${}^ET_{LH}$ 和 ${}^ET_{RH}$ 直接反映操作状态——接近、抓取或搬运——从而使表示本质上以交互为中心。将每个量都相对于场景实体而非相机来表达，可在不同视角下得到相同的标记，从而支持人到机器人的直接迁移。我们还获得了一个统一的、可变长度的接口，能够在不改架构的情况下适配不同数量物体的场景。我们通过实验表明，ICT 是跨具身迁移的关键使能因素（第 4.4 节）。

3.4 带稠密辅助目标的流匹配策略

我们的策略（图 2）以场景状态 s_t -ICT 标记和一张 RGB 图像为输入，生成一个跨度为 K 步的双手动作轨迹 $\mathbf{a} \in \mathbb{R}^{K \times D_a}$ ，其中每个 D_a 维切片拼接了双手的 6-DoF 姿态和二值抓握。训练过程如下所述。

流匹配动作生成。我们将动作生成表述为一个条件流匹配[33,64]问题：我们用一个以 s_t 为条件的 Transformer 解码器参数化速度场 v_θ ，并训练它将高斯先验样本输运到动作目标。我们的主要训练损失为：

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{t, \mathbf{x}_0, \mathbf{x}_1} \left[w_p \|\Delta \mathbf{p}\|^2 + w_r \|\Delta \mathbf{r}\|^2 + w_g \|\Delta g\|^2 \right], \quad \mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1, \quad (2)$$

其中 w_p, w_r, w_g 为位置 (p)、旋转 (r) 和抓握 (g) 的损失权重；

$\Delta(\cdot) = v_\theta(\mathbf{x}_t, t, s_t) - (\mathbf{x}_1 - \mathbf{x}_0)$ 是速度预测误差； $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1$ 是流时间 $t \sim \mathcal{U}(0, 1)$ ； $\mathbf{x}_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 下的插值样本； $t \sim \mathcal{U}(0, 1)$ ； $\mathbf{x}_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是高斯先验样本； $\mathbf{x}_1$ 是真实的双手动作。推理时，我们使用固定步长的 Euler 求解器积分学到的 ODE。

稠密辅助目标。为从每个示范中提取丰富监督，我们加入三个与流匹配头共享上下文编码器的辅助目标：（1）物体运动 ($\mathcal{L}_{\text{OM}}$)：我们预测每个被操控物体未来的 6-DoF 轨迹，迫使编码器在手部运动下建模物体动力学；（2）2D 轨迹 ($\mathcal{L}_{2\text{D}}$)：我们回归实体轨迹未来的 2D 投影，将表示锚定到视觉观测中；（3）潜在一致性 ($\mathcal{L}_{\text{LC}}$)：我们预测 K 步之后的 ICT 状态，推动编码器捕捉场景动态。我们将它们与流匹配损失结合为单一目标：

$$\mathcal{L} = \mathcal{L}_{\text{FM}} + \lambda_{\text{OM}} \mathcal{L}_{\text{OM}} + \lambda_{2\text{D}} \mathcal{L}_{2\text{D}} + \lambda_{\text{LC}} \mathcal{L}_{\text{LC}}, \quad (3)$$

其中 $\lambda_{\text{OM}}, \lambda_{2\text{D}}, \lambda_{\text{LC}}$ 是三个辅助目标的损失权重。我们从感知流水线自动推导每个辅助目标，因此每次演示都会产生密集的多任务信号。三个目标都在互补的空间中预测场景演化（3D 物理空间、2D 视觉空间、潜在空间），从而为共享编码器提供一个轻量级的手-物体交互世界模型。我们还利用共享编码器作为多任务正则器来抑制过拟合，在低数据条件下收益最大（第 4.2、4.4 节）。

4 实验

我们评估 HumanEgo 来回答四个问题：（1）能否弥合具身鸿沟，仅凭人类视频就实现可靠的操控？（第 4.1 节）（2）策略性能如何随人类数据而变化，相比匹配的机器人数据？（第 4.2 节）（3）策略在具身、视角和环境发生分布偏移时有多稳健？（第 4.3 节）（4）最终性能中各个组成部分贡献有多大？（第 4.4 节）除非另有说明，所有实验都在 Trossen WidowX 机械臂上进行，使用顶部安装的 RealSense D405（附录 D.1），并在每个任务上进行 40 次试验，物体初始位置随机化，报告成功率（%）。




图 3：四个真实世界评估任务。

每个组件对最终性能的贡献有多大？除非另有说明，所有实验都在 Trossen WidowX 机械臂上进行，顶部安装 RealSense D405（附录 D.1），并在每个任务 40 次试验中报告成功率（%），物体初始位置随机化。

4.1 HumanEgo 高效弥合具身鸿沟

我们在四个真实世界操控任务上评估 HumanEgo（图 3；细节见附录 A.2）：喂面包 Serve Bread，这是一个抓取并放置任务，机器人从任意位置抓取一根可颂并放到盘子上；下堆杯子 Downstack Cups，这是一个长时域的多步骤任务，需要依次推翻、抓取并重新堆叠三个套叠杯；浇花 Water Flowers，这是一个接触丰富的双臂任务，且时间顺序严格——一只手臂将拉出的喷头举到花盆上方，另一只手臂打开阀门；调整桌面 Adjust Table，这是一个持续的旋转控制任务——机器人抓住曲柄手柄并在不松手的情况下完成三整圈旋转。我们与五种从人类第一人称视频学习操控的零样本方法进行比较，并将它们分为三类设计。前两种是基于点的：EgoZero [21] 将第一人称场景提升到 3D 点云中，并将手和物体视为同等对象；Point Policy [20] 则在每个画面上跟踪稀疏关键点。另两种是基于目标条件的：ZeroMimic [51] 从网络视频蒸馏 3D 手腕轨迹，并在测试时以目标图像作为条件；Track2Act [19] 预测 2D 点轨迹，但不进行显式的 3D 推理。最后一种 SPOT [48] 是以物体为中心的，它使用扩散模型生成带 SE(3) 的物体轨迹。五种方法均在每个任务相同的 30 分钟人类数据上训练。我们还加入 ACT [28]：在相同硬件上收集的 30 分钟机器人遥操作数据上训练。

Overall Real-World Evaluation




图 4：整体真实世界评估。各方法在四个任务上的真实世界成功率（%）。使用 30 min 数据的 HumanEgo 在每个任务上都取得最高成功率，表明相较于人类视频基线和机器人遥操作方法，它们带来一致的提升。

HumanEgo 在每一个单独任务上都取得最高成功率。如图 4 所示，仅使用 30 分钟人类数据的 HumanEgo 在四个任务上的平均成功率达到 92.5%。相比之下，这五个基于人类视频的基线范围从 1.9% 到 45.0%，差距很大，说明每种方法只能捕捉操控的某一部分：在更简单的任务上表现尚可，但在需要精确手-物体推理的任务上会崩塌。HumanEgo 是唯一一种无论任务复杂度如何都能保持高性能的方法。

即便只有一半数据，HumanEgo 也优于机器人遥操作。仅用 15 分钟人类数据的 HumanEgo 已达到 75.0%，超过了在 30 分钟机器人遥操作数据上训练的 ACT（51.2%），凸显了我们方法的数据效率——而且现成的人类视频可能是机器人学习中非常强大的数据来源。

HumanEgo 在需要精确协调与空间推理的任务上表现出色。在 Down-stack Cups 中，这是一项长时域任务：需要按顺序把三个套叠杯依次拆开，并且在 ~ 1 cm 容差下，早期错误会不断累积；HumanEgo 的成绩达到 87.5%，而没有任何基线超过 45%。在 Water Flowers 中，机器人必须依次协调双臂——一只手臂完成其子任务后，另一只手臂才打开水龙头注水，并精确将水流对准锅中；这要求真正理解物体位置的空间关系，而不是记忆轨迹；HumanEgo 达到 95%，是最佳基线（45%）的两倍以上。

4.2 人类演示的效率

我们比较了用人类视频训练得到的 HumanEgo 与 ACT，以及用机器人遥操作训练得到的 HumanEgo；比较随采集时间变化的效果，任务为 Serve Bread（图 5）。

HumanEgo 能从极少的人类数据中有效学习。只需 ~ 7 分钟的人类演示，HumanEgo 就已达到 50% 的成功率，并且能平稳持续提升；30 分钟时达到 95%。这种陡峭且单调的扩展曲线表明，我们的流程即使从少量演示中也能提取出有用的操作信号。




图 5：数据效率。成功率（%）与数据采集时间的关系。HumanEgo 用 8 分钟的人类数据训练，超过了 ACT 用 30 分钟机器人数据训练的效果。

当演示稀缺时，辅助目标会放大学习效果。在 2 到 12 分钟之间，加入辅助损失的 HumanEgo 始终优于不加入辅助损失的对应变体；增益最大出现在 8 分钟（57.5% 对 37.5%）。超过 18 分钟后，两种变体趋于一致，在 30 分钟时都达到 95%；这证实了辅助损失能从每次演示中提取更丰富的监督信号——但随着数据变得充足，这种优势会逐渐减弱。

人类视频是一种比机器人遥操作更高效的数据来源。在 8 分钟的采集时间下，用人类视频训练的 HumanEgo (57.5%) 已经超过了用 30 分钟机器人遥操作训练的 ACT (52.5%)——采集工作量减少了 3.75 倍。离线指标进一步确认，人类演示具有更高的空间密度与轨迹多样性，从而能在每分钟采集时间里产生更高质量的训练信号（图 6）。

4.3 一种策略，多种条件

我们在 Serve Bread 和 Downstack Cups 上部署 HumanEgo，覆盖 9 种分布外条件——无需任何重新训练或微调

（每个任务各 40 次试验；结果见图 7，真实世界设置见图 8）。




图 7：零样本跨条件泛化。HumanEgo 在不同条件下无需重新训练，依然保持强健的成功率。

HumanEgo 对任意视觉条件都很鲁棒。更换背景、照明、视角或添加干扰物，在大多数情况下都能得到 85% 到 91.25% 的成功率，且没有可测的退化。该策略甚至能处理训练集中从未出现过的新的物体实例，表明它能从视觉输入中有效提取与任务相关的信息，同时对无关变化保持不变。

HumanEgo 对任意物体摆放位置也很鲁棒。在 Serve Bread 中，它能将面包送到餐盘上，无论桌面上的绝对与相对位置如何，甚至在新的高度也同样可行；在 Down-stack Cups 中，它能在不同的桌面高度与杯子位置下完成三步序列——在这些场景里，像 EgoZero [21] 和 PointPolicy [20] 等方法往往会失败。除了这一量化评估之外，我们在 Water Flowers 上也从定性观察到类似的摆放鲁棒性：无论水槽中的位置在哪里，机器人都能将水龙头对准锅中。这种鲁棒性反映了我们在以交互为中心的表示中嵌入的物体中心结构，从而实现摆放不变性。

HumanEgo 不依赖特定硬件。所有训练数据都用 Aria 眼镜采集，但在推理阶段，无论部署硬件是什么，策略都能取得较高的成功率——相机是 RealSense 还是 ZED，机器人机械臂是 Trossen、Franka 还是 UR10。训练与部署设置之间没有共同的硬件，但策略仍能无缝迁移——这得益于第 4.4 节中详述的帧不变表示与训练架构。

4.4 是什么驱动 HumanEgo 的性能？

我们在 Water Flowers 上消融 HumanEgo 的两个核心设计选择：空间表示（图 9）和辅助训练目标（图 10）。

显式空间表示，而非视觉保真度，是弥合具身差距的关键。我们将视觉预处理与空间表示分离。逐步缩小视觉具身差距——从原始人类 RGB（7.5%）到带手臂修补的关键点渲染（20%），再到




图 6：人类数据 vs 机器人数据。人类的全程视角数据具有更高的信噪比（SNR）、更平滑的运动、更少的空闲时间（上图），以及更大的空间与轨迹多样性（下图）。




图 8：跨条件的真实世界评估：跨躯体 / 环境 / 设置。




Fig. 9: **Representation study.** Success rate (%) for five input configurations. Visual-only methods plateau at 32.5% with any strategy; adding spatial tokens yields +52.5 pp.




Fig. 10: **Auxiliary training study.** Success rate (%) at 15 min of data for each auxiliary objective individually. Object motion contributes the most (+17.5 pp); all three combine for +25 pp.

完全消除差距的机器人 RGB (32.5%) —— 只带来有限提升；即使视觉不匹配为零，策略也仅略高于 30%。单目 RGB 编码的是外观，而不是操作所需的三维空间关系。将 ICT 加到原始人类 RGB 上，性能从 7.5% 戏剧性跃升到 85%，完整系统达到 95%。ICT 直接编码双手与物体之间的相对 6-DoF 变换——这一核心操作状态——把从像素中推断三维动力学的问题，转化为从显式空间关系中学习动作的问题。

辅助目标带来互补收益。我们在 15 分钟数据下分别评估每个目标。每个损失都能独立提升性能：物体运动 (+17.5 个百分点)、潜在一致性 (+12.5 个百分点) 和 2D 轨迹 (+5 个百分点)。组合后，相较基础模型累计提升 +25 个百分点。从高层看，这三种目标都在不同空间中执行前向动力学预测——预测操作状态如何演化——分别对应 3D 物理空间、2D 视觉空间和潜在状态嵌入，迫使共享编码器学习操作的因果结构，而不仅仅是视觉外观。综合这些消融结果，支持了主要实验论点：ICT 提供可迁移的操作状态，而密集的辅助监督使这种状态能够从几分钟的人类视频中学习到。

5 结论

我们提出了 HumanEgo，这一框架可仅从几分钟的人类第一视角视频中学习机器人操作策略——无需任何机器人数据或大规模预训练。HumanEgo 采用一种与硬件无关的表示，通过视觉预处理（手臂修补、关键点渲染）和空间编码（ICT）弥合具身差距，使所学策略对具身形式、视角和环境保持不变。结合流匹配策略以及在互补空间中监督前向动力学的密集辅助目标，HumanEgo 在四个真实世界任务上达到 92.5% 的平均成功率，优于五种近期基于人类视频的基线，相比等时长的机器人遥操作提升 41%，并且无需任何再训练即可零样本泛化到新的机器人具身、相机设置和真实环境。

局限与未来工作。我们的框架依赖 Aria 的双目手部跟踪——单目替代方案会显著降低真实世界成功率（附录 E.1），这表明需要更强的单目手部姿态估计器来恢复绝对深度。我们使用逐帧物体检测而非实时跟踪；涉及遮挡或快速运动的手内操作和其他动态场景将需要在线、对遮挡鲁棒的跟踪器。该流水线串联了多个现成的感知模块，其失败会级联到策略中，这促使我们需要更强或联合训练的前端。最后，少样本学习在 ~ 1 cm 精度处趋于平台期；在接触密集任务上达到厘米以下精度，可能需要强化学习细化或基于仿真的微调。我们将 HumanEgo 视为一个起点——一个完全零样本、无需机器人数据的流水线，未来工作可在其上扩展在线跟踪、学习式前端和下游 RL 细化。

致谢

我们感谢 Eadom Dessalene、Yoonkyo Jung、Zikui Cai 以及 PRG Lab 和 Furong's Lab 的其他成员在本项目中的宝贵反馈与支持。

参考文献

- [1] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn, P. Florence, C. Fu, M. G. Arenas, K. Gopalakrishnan, K. Han, K. Hausman, A. Herzog, J. Hsu, B. Ichter, A. Irpan, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, L. Lee, T.-W. E. Lee, S. Levine, Y. Lu, H. Michalewski, I. Mordatch, K. Pertsch, K. Rao, K. Reymann, M. Ryoo, G. Salazar, P. Sanketi, P. Sermanet, J. Singh, A. Singh, R. Soricut, H. Tran, V. Vanhoucke, Q. Vuong, A. Wahid, S. Welker, P. Wohlhart, J. Wu, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich. RT-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- [2] ALOHA 2 Team, J. Aldaco, T. Armstrong, R. Baruch, J. Bingham, S. Chan, K. Draper, D. Dwibedi, C. Finn, P. Florence, S. Goodrich, W. Gramlich, T. Hage, A. Herzog, J. Hoech, T. Nguyen, I. Storz, B. Tabanpour, L. Takayama, J. Thompson, A. Wahid, T. Wahrburg, S. Xu, S. Yaroshenko, K. Zakka, and T. Z. Zhao. ALOHA 2: An enhanced low-cost hardware for bimanual teleoperation. *arXiv preprint arXiv:2405.02292*, 2024.
- [3] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems (RSS)*, 2023.
- [4] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis, P. D. Fagan, J. Hejna, M. Itkina, M. Lepert, Y. J. Ma, P. T. Miller, J. Wu, S. Belkhale, S. Dass, H. Ha, A. Jain, A. Lee, Y. Lee, M. Memmel, S. Park, I. Radosavovic, K. Wang, A. Zhan, K. Black, C. Chi, K. B. Hatch, S. Lin, J. Lu, J. Mercat, A. Rehman, P. R. Sanketi, A. Sharma, C. Simpson, Q. Vuong, H. R. Walke, B. Wulfe, T. Xiao, J. H. Yang, A. Yavary, T. Z. Zhao, C. Agia, R. Baijal, M. G. Castro, D. Chen, Q. Chen, T. Chung, J. Drake, E. P. Foster, J. Gao, V. Guizilini, D. A. Herrera, M. Heo, K. Hsu, J. Hu, M. Z. Irshad, D. Jackson, C. Le, Y. Li, K. Lin, R. Lin, Z. Ma, A. Maddukuri, S. Mirchandani, D. Morton, T. Nguyen, A. O'Neill, R. Scalise, D. Seale, V. Son, S. Tian, E. Tran, A. E. Wang, Y. Wu, A. Xie, J. Yang, P. Yin, Y. Zhang, O. Bastani, G. Berseth, J. Bohg, K. Goldberg, A. Gupta, A. Gupta, D. Jayaraman, J. J. Lim, J. Malik, R. Martín-Martín, S. Ramamoorthy, D. Sadigh, S. Song, J. Wu, M. C. Yip, Y. Zhu, T. Kollar, S. Levine, and C. Finn. DROID: A large-scale in-the-wild robot manipulation dataset. In *Robotics: Science and Systems (RSS)*, 2024.
- [5] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. P. Foster, P. R. Sanketi, Q. Vuong, T. Kollar, B. Burchfiel, R. Tedrake, D. Sadigh, S. Levine, P. Liang, and C. Finn. OpenVLA: An open-source vision-language-action model. In *8th Annual Conference on Robot Learning*, 2024. URL <https://openreview.net/forum?id=ZMnD6QZAE6>.
- [6] K. Black, N. Brown, J. Darpinian, K. Dhabalia, D. Driess, A. Esmail, M. R. Equi, C. Finn, N. Fusai, M. Y. Galliker, D. Ghosh, L. Groom, K. Hausman, brian ichter, S. Jakubczak, T. Jones, L. Ke, D. LeBlanc, S. Levine, A. Li-Bell, M. Mothukuri, S. Nair, K. Pertsch, A. Z. Ren, L. X. Shi, L. Smith, J. T. Springenberg, K. Stachowicz, J. Tanner, Q. Vuong, H. Walke, A. Walling, H. Wang, L. Yu, and U. Zhilinsky. $\pi_{0.5}$: a vision-language-action model with open-world generalization. In *9th Annual Conference on Robot Learning*, 2025. URL <https://openreview.net/forum?id=vlhoswksB0>.
- [7] J. Engel, K. Somasundaram, M. Goesele, A. Sun, A. Gamino, A. Turner, A. Talattof, A. Yuan, B. Souti, B. Meredith, C. Peng, C. Sweeney, C. Wilson, D. Barnes, D. DeTone, D. Caruso, D. Valleroy, D. Ginjupalli, D. Frost, E. Miller, E. Mueggler, E. Oleinik, F. Zhang, G. Somasundaram, G. Solaira, H. Lanaras, H. Howard-Jenkins, H. Tang, H. J. Kim, J. Rivera, J. Luo,

- J. Dong, J. Straub, K. Bailey, K. Eickenhoff, L. Ma, L. Pesqueira, M. Schwesinger, M. Monge, N. Yang, N. Charron, N. Raina, O. Parkhi, P. Borschowa, P. Moulon, P. Gupta, R. Mur-Artal, R. Pennington, S. Kulkarni, S. Miglani, S. Gondi, S. Solanki, S. Diener, S. Cheng, S. Green, S. Saarinen, S. Patra, T. Mourikis, T. Whelan, T. Singh, V. Balntas, V. Baiyya, W. Dreewes, X. Pan, Y. Lou, Y. Zhao, Y. Mansour, Y. Zou, Z. Lv, Z. Wang, M. Yan, C. Ren, R. De Nardi, and R. Newcombe. Project Aria: A new tool for egocentric multi-modal AI research. *arXiv preprint arXiv:2308.13561*, 2023.
- [8] S. Kareer, D. Patel, R. Punamiya, P. Mathur, S. Cheng, C. Wang, J. Hoffman, and D. Xu. EgoMimic: Scaling imitation learning via egocentric video. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2025.
- [9] R. Punamiya, D. Patel, P. Aphiwetsa, P. Kuppili, L. Y. Zhu, S. Kareer, J. Hoffman, and D. Xu. EgoBridge: Domain adaptation for generalizable imitation from egocentric human data. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- [10] Y. Liu, W. C. Shin, Y. Han, Z. Chen, H. Ravichandar, and D. Xu. ImMimic: Cross-domain imitation from human videos via mapping and interpolation. *arXiv preprint arXiv:2509.10952*, 2025.
- [11] R.-Z. Qiu, S. Yang, X. Cheng, C. Chawla, J. Li, T. He, G. Yan, D. J. Yoon, R. Hoque, L. Paulsen, G. Yang, J. Zhang, S. Yi, G. Shi, and X. Wang. Humanoid policy ~ human policy. In *9th Annual Conference on Robot Learning*, 2025. URL <https://openreview.net/forum?id=Tx54fkQ3Cq>.
- [12] R. Yang, Q. Yu, Y. Wu, R. Yan, B. Li, A.-C. Cheng, X. Zou, Y. Fang, X. Cheng, R.-Z. Qiu, H. Yin, S. Liu, S. Han, Y. Lu, and X. Wang. EgoVLA: Learning vision-language-action models from egocentric human videos. *arXiv preprint arXiv:2507.12440*, 2025.
- [13] R. Zheng, D. Niu, Y. Xie, J. Wang, M. Xu, Y. Jiang, F. Castañeda, F. Hu, Y. L. Tan, L. Fu, T. Darrell, F. Huang, Y. Zhu, D. Xu, and L. Fan. EgoScale: Scaling dexterous manipulation with diverse egocentric human data. *arXiv preprint arXiv:2602.16710*, 2026.
- [14] R. Punamiya, S. Kareer, Z. Liu, J. Citron, R.-Z. Qiu, X. Cai, A. Gavryushin, J. Chen, D. Li-conti, L. Y. Zhu, P. Aphiwetsa, B. Li, A. Cheluva, P. Kuppili, Y. Liu, D. Patel, M. Pollefeys, R. Katzschmann, X. Wang, S. Song, J. Hoffman, D. Xu, et al. EgoVerse: An egocentric human dataset for robot learning from around the world. *arXiv preprint arXiv:2604.07607*, 2026.
- [15] R. Hoque, P. Huang, D. J. Yoon, M. Sivapurapu, and J. Zhang. EgoDex: Learning dexterous manipulation from large-scale egocentric video. In *International Conference on Learning Representations (ICLR)*, 2026.
- [16] M. Lepert, J. Fang, and J. Bohg. Phantom: Training robots without robots using only human videos. In *Conference on Robot Learning (CoRL)*, 2025.
- [17] M. Lepert, J. Fang, and J. Bohg. Masquerade: Learning from in-the-wild human videos using data-editing. *arXiv preprint arXiv:2508.09976*, 2025.
- [18] E. Dessalene, P. Mantripragada, M. Maynord, and Y. Aloimonos. EmbodiSwap for zero-shot robot imitation learning. *arXiv preprint arXiv:2510.03706*, 2025.
- [19] H. Bharadhwaj, R. Mottaghi, A. Gupta, and S. Tulsiani. Track2Act: Predicting point tracks from internet videos enables generalizable robot manipulation. In *European Conference on Computer Vision (ECCV)*, 2024.
- [20] S. Haldar and L. Pinto. Point policy: Unifying observations and actions with key points for robot manipulation. In *Conference on Robot Learning (CoRL)*, 2025.

- [21] V. Liu, A. Adeniji, H. Zhan, S. Haldar, R. Bhirangi, P. Abbeel, and L. Pinto. EgoZero: Robot learning from smart glasses. *arXiv preprint arXiv:2505.20290*, 2025.
- [22] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar. MimicPlay: Long-horizon imitation learning by watching human play. In *Conference on Robot Learning (CoRL)*, 2023.
- [23] G. Li, Y. Lyu, Z. Liu, C. Hou, J. Zhang, and S. Zhang. H2R: A human-to-robot data augmentation for robot pre-training from videos. *arXiv preprint arXiv:2505.11920*, 2025.
- [24] M. Xu, Z. Xu, C. Chi, M. Veloso, and S. Song. XSkill: Cross embodiment skill discovery. In *7th Annual Conference on Robot Learning*, 2023. URL <https://openreview.net/forum?id=8L6pHd9aS6w>.
- [25] M. Xu, Z. Xu, Y. Xu, C. Chi, G. Wetzstein, M. Veloso, and S. Song. Flow as the cross-domain manipulation interface. In *Conference on Robot Learning (CoRL)*, 2024.
- [26] V. Jain, M. Attarian, N. J. Joshi, A. Wahid, D. Driess, Q. Vuong, P. R. Sanketi, P. Sermanet, S. Welker, C. Chan, I. Gilitschenski, Y. Bisk, and D. Dwibedi. Vid2Robot: End-to-end video-conditioned policy learning with cross-attention transformers. In *Robotics: Science and Systems (RSS)*, 2024.
- [27] C. Wen, X. Lin, J. So, K. Chen, Q. Dou, Y. Gao, and P. Abbeel. Any-point trajectory modeling for policy learning, 2024. URL <https://arxiv.org/abs/2401.00025>.
- [28] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Robotics: Science and Systems (RSS)*, 2023.
- [29] K. Yu, S. Zhang, H. Soora, F. Huang, H. Huang, P. Tokekar, and R. Gao. GenFlowRL: Shaping rewards with generative object-centric flow in visual reinforcement learning. *arXiv preprint arXiv:2508.11049*, 2025.
- [30] H. Li, L. Sun, Y. Hu, D. Ta, J. Barry, G. Konidaris, and J. Fu. NovaFlow: Zero-shot manipulation via actionable flow from generated videos. *arXiv preprint arXiv:2510.08568*, 2025.
- [31] S. Patel, S. Mohan, H. Mai, U. Jain, S. Lazebnik, and Y. Li. Robotic manipulation by imitating generated videos without physical demonstrations. *arXiv preprint arXiv:2507.00990*, 2025.
- [32] K. Yu, Y. Han, Q. Wang, V. Saxena, D. Xu, and Y. Zhao. Mimictouch: Leveraging multi-modal human tactile demonstrations for contact-rich manipulation. In *8th Annual Conference on Robot Learning*, 2024. URL <https://openreview.net/forum?id=7yMZAUKXa4>.
- [33] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le. Flow matching for generative modeling. In *International Conference on Learning Representations (ICLR)*, 2023.
- [34] K. Grauman, A. Westbury, E. Byrne, Z. Chavis, A. Furnari, R. Girdhar, J. Hamburger, H. Jiang, M. Liu, X. Liu, M. Martin, T. Nagarajan, I. Radosavovic, S. K. Ramakrishnan, F. Ryan, J. Sharma, M. Wray, M. Xu, E. Z. Xu, C. Zhao, et al. Ego4D: Around the world in 3,000 hours of egocentric video. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [35] D. Damen, H. Doughty, G. M. Farinella, A. Furnari, E. Kazakos, J. Ma, D. Moltisanti, J. Munro, T. Perrett, W. Price, and M. Wray. Rescaling egocentric vision: Collection pipeline and challenges for EPIC-KITCHENS-100. *International Journal of Computer Vision (IJCV)*, 2022.
- [36] P. Banerjee, S. Shkodrani, P. Moulon, S. Hampali, F. Zhang, J. Fountain, E. Miller, S. Basol, R. Newcombe, R. Wang, J. J. Engel, and T. Hodan. Introducing HOT3D: An egocentric dataset for 3d hand and object tracking. *arXiv preprint arXiv:2406.09598*, 2024.

- [37] Y. Liu, Y. Liu, C. Jiang, K. Lyu, W. Wan, H. Shen, B. Liang, Z. Fu, H. Wang, and L. Yi. HOI4D: A 4d egocentric dataset for category-level human-object interaction. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [38] Y. Liu, H. Yang, X. Si, L. Liu, Z. Li, Y. Zhang, Y. Liu, and L. Yi. TACO: Benchmarking generalizable bimanual tool-ACTION-object understanding. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.
- [39] X. Wang, T. Kwon, M. Rad, B. Pan, I. Chakraborty, S. Andrist, D. Bohus, A. Feniello, B. Tekin, F. V. Frujeri, N. Joshi, and M. Pollefeys. HoloAssist: An egocentric human interaction dataset for interactive AI assistants in the real world. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.
- [40] G. Zhang, Q. Xu, H. Zhang, J. Ma, L. He, Y. Bao, Z. Ping, Z. Yuan, C. Lu, C. Yuan, T. Liang, X. Tian, M. Shao, F. Zhang, M. Ding, Y. Gao, H. Zhao, H. Zhao, and H. Xu. UniDex: A robot foundation suite for universal dexterous hand control from egocentric human videos. *arXiv preprint arXiv:2603.22264*, 2026.
- [41] S. Lee, Y. Jung, I. Chun, Y.-C. Lee, Z. Cai, H. Huang, A. Talreja, T. D. Dao, Y. Liang, J.-B. Huang, and F. Huang. TraceGen: World modeling in 3d trace-space enables learning from cross-embodiment videos. *arXiv preprint arXiv:2511.21690*, 2025.
- [42] C. Yuan, C. Wen, T. Zhang, and Y. Gao. General flow as foundation affordance for scalable robot learning. In *8th Annual Conference on Robot Learning*, 2024. URL <https://openreview.net/forum?id=nMEt0ci8hi>.
- [43] L. Y. Zhu, P. Kuppili, R. Punamiya, P. Aphiwetsa, D. Patel, S. Kareer, S. Ha, and D. Xu. EMMA: Scaling mobile manipulation via egocentric human data. *IEEE Robotics and Automation Letters*, 2025.
- [44] S. Kareer, K. Pertsch, J. Darpinian, J. Hoffman, D. Xu, S. Levine, C. Finn, and S. Nair. Emergence of human to robot transfer in vision-language-action models. *Preprint*, 2025.
- [45] H. Kim, J. Kang, H. Kang, M. Cho, S. J. Kim, and Y. Lee. Uniskill: Imitating human videos via cross-embodiment skill representations. In *9th Annual Conference on Robot Learning*, 2025. URL <https://openreview.net/forum?id=EgSDP6A0F1>.
- [46] I. Guzey, H. Qi, J. Urain, C. Wang, J. Yin, K. Bodduluri, M. Lambeta, L. Pinto, A. Rai, J. Malik, T. Wu, A. Sharma, and H. Bharadhwaj. Dexterity from smart lenses: Multi-fingered robot manipulation with in-the-wild human demonstrations. *arXiv preprint arXiv:2511.16661*, 2025.
- [47] A. Singh, K. Torshizi, K. Habib, K. Yu, R. Gao, and P. Tokekar. Afford2Act: Affordance-guided automatic keypoint selection for generalizable and lightweight robotic manipulation. *arXiv preprint arXiv:2510.01433*, 2025.
- [48] C.-C. Hsu, B. Wen, J. Xu, Y. Narang, X. Wang, Y. Zhu, J. Biswas, and S. Birchfield. SPOT: SE(3) pose trajectory diffusion for object-centric manipulation. *arXiv preprint arXiv:2411.00965*, 2024.
- [49] Y. Zou, C. Shi, W. Yu, H. Xue, J. Lv, Y. Pan, C. Wen, and C. Lu. ActiveGlasses: Learning manipulation with active vision from ego-centric human demonstration. *arXiv preprint arXiv:2604.08534*, 2026.
- [50] Z.-H. Yin, S. Yang, and P. Abbeel. Object-centric 3d motion field for robot learning from human videos. *arXiv preprint arXiv:2506.04227*, 2025.
- [51] J. Shi, Z. Zhao, T. Wang, I. Pedroza, A. Luo, J. Wang, J. Ma, and D. Jayaraman. ZeroMimic: Distilling robotic manipulation skills from web videos. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2025.

- [52] S. Park, H. Bharadhwaj, and S. Tulsiani. DemoDiffusion: One-shot human imitation using pre-trained diffusion policy. *arXiv preprint arXiv:2506.20668*, 2025.
- [53] R. Shah, S. Liu, Q. Wang, Z. Jiang, S. Kumar, M. Seo, R. Martín-Martín, and Y. Zhu. MimicDroid: In-context learning for humanoid robot manipulation from human play videos. *arXiv preprint arXiv:2509.09769*, 2025.
- [54] H. Chen, T. Dong, T. Wu, L. Wang, Y. Jangir, Y. Niu, Y. Ye, H. Bharadhwaj, Z. Erickson, and J. Ichnowski. Dexterous manipulation policies from RGB human videos via 3d hand-object trajectory reconstruction. *arXiv preprint arXiv:2602.09013*, 2026.
- [55] J. Shi, J. Smith, J. Qian, and D. Jayaraman. Points2Reward: Robotic manipulation rewards from just one video. In *RSS Workshop on Semantic Robotics (SemRob)*, 2025.
- [56] B. Wang, N. Sridhar, C. Feng, M. van der Merwe, A. Fishman, N. Fazeli, and J. J. Park. This&that: Language-gesture controlled video generation for robot planning. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 12842–12849, 2025. doi: [10.1109/ICRA55743.2025.11128780](https://doi.org/10.1109/ICRA55743.2025.11128780).
- [57] H. Xiong, Q. Li, Y.-C. Chen, H. Bharadhwaj, S. Sinha, and A. Garg. Learning by watching: Physical imitation of manipulation skills from human videos. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 7827–7834, 2021. doi:[10.1109/IROS51168.2021.9636080](https://doi.org/10.1109/IROS51168.2021.9636080).
- [58] R. Suvorov, E. Logacheva, A. Mashikhin, A. Remizova, A. Ashukha, A. Silvestrov, N. Kong, H. Goka, K. Park, and V. Lempitsky. Resolution-robust large mask inpainting with Fourier convolutions. In *IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2022.
- [59] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, Q. Jiang, C. Li, J. Yang, H. Su, J. Zhu, and L. Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *European Conference on Computer Vision (ECCV)*, 2024.
- [60] N. Ravi, V. Gabeur, Y.-T. Hu, R. Hu, C. Ryali, T. Ma, H. Khedr, R. Rädle, C. Rolland, L. Gustafson, E. Mintun, J. Pan, K. V. Alwala, N. Carion, C.-Y. Wu, R. Girshick, P. Dollár, and C. Feichtenhofer. SAM 2: Segment anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.
- [61] N. Karaev, I. Rocco, B. Graham, N. Neverova, A. Vedaldi, and C. Rupprecht. CoTracker: It is better to track together. In *European Conference on Computer Vision (ECCV)*, 2024.
- [62] Z. Wang, Z. Zhang, J. Xu, J. Wang, T. Pang, C. Du, H. Zhao, and Z. Zhao. Orient anything V2: Unifying orientation and rotation understanding. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- [63] Y. Zhou, C. Barnes, J. Lu, J. Yang, and H. Li. On the continuity of rotation representations in neural networks. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [64] X. Liu, C. Gong, and Q. Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *International Conference on Learning Representations (ICLR)*, 2023.
- [65] R. A. Potamias, J. Zhang, J. Deng, and S. Zafeiriou. WiLoR: End-to-end 3d hand localization and reconstruction in-the-wild. *arXiv preprint arXiv:2409.12259*, 2024.
- [66] G. Pavlakos, D. Shan, I. Radosavovic, A. Kanazawa, D. Fouhey, and J. Malik. Reconstructing hands in 3D with transformers. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.

- [67] Z. Yu, S. Zafeiriou, and T. Birdal. Dyn-HaMR: Recovering 4d interacting hand motion from a dynamic camera. *arXiv preprint arXiv:2412.12861*, 2025.
- [68] J. Zhang, J. Deng, C. Ma, and R. A. Potamias. HaWoR: World-space hand motion reconstruction from egocentric videos. *arXiv preprint arXiv:2501.02973*, 2025.
- [69] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, F. Zhang, C.-L. Chang, M. G. Yong, J. Lee, W.-T. Chang, W. Hua, M. Georg, and M. Grundmann. MediaPipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019.
- [70] X. Zhang, Z. Kou, C. Qin, M. Huang, E. Ristani, A. Kumar Lele, L. Chen, K. He, A. Boularias, and L. Guan. Glove2Hand: Synthesizing natural hand-object interaction from multi-modal sensing gloves. *arXiv preprint arXiv:2603.20850*, 2026.
- [71] A. Sarker, Z. Kou, E. Ristani, L. Guan, and T. Niehues. Real-time hand pose tracking using 6-axis IMUs. In *ACM/IEEE International Conference on Human-Robot Interaction (HRI)*, 2026.

附录

A 数据采集细节

A.1 Aria Gen1 眼镜

Aria Gen1 录制配置。我们使用 Project Aria Gen1 眼镜记录每个人工演示，并通过官方 Project Aria Mobile App 进行配置，传感器配置文件如下所列：

- RGB：2 MP 下以 30 fps。
- SLAM：2× 单色摄像头，VGA 分辨率下 30 fps。
- ET（眼动追踪）：2× 摄像头，QVGA 下 10 fps。
- IMUs：在 1000 Hz 和 800 Hz 采样的两个 6 轴 IMU。
- 磁力计、气压计、7 麦克风音频阵列、GPS、Wi-Fi 和 BLE：均已启用，用于同步元数据和环境上下文。

所有流都在设备上硬件时间戳标记，并与统一的 Aria 时钟同步，因此每种模态在毫秒级都实现时间对齐。



图 11：数据采集设置。

Aria 机器感知服务。基于原始记录-

Aria 的云托管机器感知服务（MPS）[7] 将每次采集的内容后处理为可度量、随时可用的信号。我们的流程中有两个 MPS 输出至关重要：

- 闭环轨迹。闭环 SLAM 输出将双目单色 SLAM 摄像头和双 IMU 融合，并结合闭环检测与全局优化，得到在重力对齐世界坐标系中的全局一致、已校正漂移的 6-DoF 设备轨迹。我们在每一帧 RGB 图像中查询该轨迹，以获得用于三角测量的已标定相机外参（附录 B.1），并将每个手部关键点提升到 ICT（第 3.3 节）所使用的世界坐标系中。
- 手部跟踪。MPS 手部跟踪器联合处理立体 SLAM 相机，为每只手生成 21 个 3D 关键点（每个手指五个加上手腕），直接在世界坐标系中报告，并附带每个关键点的置信度分数。这提供了我们的手到夹爪重映射所使用的 3D 手部骨架（附录 B.3）。

闭环轨迹与手部跟踪器结合，在每一帧都提供一个 6 自由度的相机位姿指标以及一个三维手部骨架，无需任何校准或场景布设，仅需佩戴这些眼镜。

A.2 任务细节

我们在四个真实世界的操作任务上评估 HumanEgo，涵盖抓取与放置、多步双手协同、接触丰富的推理以及持续的旋转控制（图3）。对于每项任务，我们将描述场景、每次试验的随机化方式、目标行为，以及用于对主论文中报告的每种条件下的40次试验进行评分所采用的成功/失败标准。

递送面包。场景。一根羊角面包和一个餐盘放在桌面上，餐盘在左，面包在右。随机化。在多次试验中，我们独立随机化：(i) 两个物体之间的水平偏移量，从 $[0, 50]$ cm 采样；以及 (ii) 它们在桌面前后轴方向上的深度，因此这对物体通常不共线。右臂从面包上方一个任意的、未对齐的姿态开始。目标行为。从上方抓取羊角面包，将其抬离桌面，运送到位于餐盘中心上方的放置姿态，并打开夹爪。成功。羊角面包放置在餐盘上，且任意朝向。失败。(a) 面包落在餐盘之外（在桌上、搭在盘沿上，或被撞落）；或 (b) 在运输过程中，面包从夹爪中滑落。

下压杯子。场景。桌面上有三个颜色各异的杯子：右下方是一个白色杯子，左下方是一个深蓝色杯子，另有一个浅蓝色杯子叠放在白色杯子上方。桌面高度以及杯子组的绝对位置在不同试次中会变化。随机化。该

白杯与深蓝杯之间的水平间隙取自 $[0, 1]\text{cm}$ ；浅蓝杯在白杯顶部的 $[0, 2]\text{cm}$ 内左右抖动。目标行为。三步序列：（1）横向推翻并撞倒浅蓝杯，使其落在深蓝杯之上；（2）越过抓取去白杯上方，从上方抓住它；（3）将白杯盖下放到深蓝/浅蓝的堆叠上并松开，在左侧形成三杯塔（深蓝/浅蓝/白，从下到上）。成功。三个杯子最终在左侧形成预期的稳定堆叠。失败。（a）从未接触到浅蓝杯；（b）将其推翻了，但它没有落到深蓝杯上；（c）没有抓取白杯；或（d）白杯没有正确放到堆叠上（没对上、推翻了它、或落在偏轴位置导致塔倒塌）。早期错误会叠加，因此策略必须在每个子阶段都成功。

给水花朵。场景。工作空间前方有一个壁挂式水龙头，桌面下方直接正对着水槽凹入在 $\sim 10\text{ cm}$ 之下。一个装有新鲜花朵的花盆放在水槽内。随机化。花盆放在水槽内三个定性不同的位置之一（左上、中央或右下）；水龙头可在 $[-15^\circ, +15^\circ]$ 内绕其竖直轴自由旋转。目标行为。双臂协同执行，并严格按时间顺序进行。左臂（喷头）：抓住伸出的喷头，将其 $\sim 15\text{ cm}$ 向下从水龙头插座中拉出，并将喷嘴保持在花盆中心上方3-5厘米处，朝下。右臂（把手）：在左臂操作期间，保持其可见的静止预抓姿态，位于水龙头把手附近；当左臂就位后，抓住把手，将其向右拨动3-5厘米以打开阀门，使水流到花朵上。成功。左臂将喷头保持在花盆上方，而右臂已打开阀门，水正浇在花朵上。失败。左臂：（a）未抓住喷头或未向下拉；（b）在拉出或搬运过程中滑脱；或（c）未放置在花盆正上方。右臂：（a）未抓住把手；或（b）拨动不够远以打开阀门，或在水流出前就发生滑脱。

调整桌面。场景。操作员面对一张可调节桌子，桌面高度由从其侧面伸出的手摇柄控制，该手摇柄大致呈水平取向。随机化。手摇柄绕其旋转轴的初始角度在水平附近由 $\pm 10^\circ$ 抖动。目标行为。右臂（1）从任意初始姿态接近手摇柄并牢牢抓住它，然后（2）绕手摇柄轴持续进行逆时针旋转，完成三整圈（ $3 \times 360^\circ$ ），且在整个过程中不松开把手。成功。在整个抓握始终保持的情况下，完成全部三整圈。失败。（a）从未抓住把手；或（b）在旋转过程中，把手在夹爪中打滑，在完成三整圈之前。

逐次示范采集时间。四项任务之中，每次单个人类第一视角示范大约需要30-40秒；在相同硬件上进行一次匹配的遥操作示范需要60-70秒。大约 $2\times$ 的差距反映出：日常的人类操作天然比通过操控界面进行的遥操作更快且更灵巧；再结合与具身无关的表示，这使得人类视频成为一种在每分钟采集量下更高采样效率的训练来源。

额外任务（仅示范）。在上文定量评估的四项任务之外，我们还收集并训练了 HumanEgo 策略用于另外五项任务，展示了我们的流程能多快应用到新的行为上。这些任务出现在我们的补充示范视频中，但不属于第4.1节中的定量评估部分。

为设备充电。操作员将一块智能手表、一副耳机和一部手机从桌面上放到它们各自的磁性充电器上。每件物品都被视为一个独立的子任务，遵循“抓取 → 运输 → 释放到垫上”的模板；我们为每个子任务收集并训练一个专用模型。

拧开瓶盖。双手任务：一只手抓住并稳住瓶身，另一只手抓住瓶盖，将其旋转2-3整圈以脱开螺纹，然后将已松开的瓶盖放到一旁。

打开门：操作员打开一扇自回弹门，该门配有杠杆式把手。执行手抓住杠杆，顺时针旋转以释放门闩，然后将门向外拉开，抵抗其回位弹簧的作用。

打开柜门。双手任务：两只手同时抓住柜门上一对竖直放置的把手，并沿向外的弧线将柜门拉开。

抓取纸巾。操作员从纸巾盒中夹取一张纸巾，将其向上提起，然后横向移动以将其完全取出，并将其放到桌面上。

B 预处理细节

B.1 三角测量

Aria Gen1 眼镜没有深度传感器，因此我们通过在帧间对跟踪到的 2D 关键点进行三角测量来恢复每个物体的 3D 位置，将移动的头戴相机视为一个多视角系统，其校准外参由 6-DoF Aria MPS SLAM 位姿 [7] 给出。这要求物体在观察窗口内保持静止；一旦开始操作，物体就可以自由移动。

前置场景扫视。多视角三角测量要求同一个 3D 点从足够不同的视角被看到，但在操作过程中，头戴相机通常几乎静止，而只有手在移动，导致有效相机基线坍塌。因此，我们在每段演示前都加一个简短的场景扫视：演示者保持场景静止，并在 $\sim 1 - 2$ 秒（ $\sim 30 - 60$ 帧）内缓慢移动头部，采用从左到右的水平平移或向前靠近物体的步行方式，然后再进行实际操作。

基于 2D 跟踪的多视角三角测量。对于每个物体，我们先在第一帧扫视图像中用 Grounding DINO [59] 检测它，用 SAM2 [60] 分割它，在得到的掩码上采样 N 个关键点，并用 CoTracker3 [61] 在 F 帧扫视序列中跟踪它们。设 $K \in \mathbb{R}^{3 \times 3}$ 为 RGB 内参， $T_i = [R_i \mid t_i]$ 为第 i 帧的相机到世界 SLAM 位姿， $P_i = K [R_i^\top \mid -R_i^\top t_i] \in \mathbb{R}^{3 \times 4}$ 为对应的世界到图像投影。一个轨迹 $\{\mathbf{u}_n^{(i)}\}_{i=1}^F$ 与未知的 3D 点 $\mathbf{X}_n \in \mathbb{R}^4$ （齐次）满足 $\mathbf{u}_n^{(i)} \times P_i \mathbf{X}_n = 0$ ，从而每一帧得到两个线性方程：

$$\begin{bmatrix} u_n^{(i)} \mathbf{p}_3^{(i)\top} - \mathbf{p}_1^{(i)\top} \\ v_n^{(i)} \mathbf{p}_3^{(i)\top} - \mathbf{p}_2^{(i)\top} \end{bmatrix} \mathbf{X}_n = 0, \quad (4)$$

其中 $\mathbf{p}_j^{(i)\top}$ 是 j 的第 P_i 行。将所有 F 帧中的(4)堆叠起来，可得到一个 $2F \times 4$ 系统 $A_n \mathbf{X}_n = 0$ ；我们通过SVD以最小二乘意义求解，取 A_n 中最小奇异值对应的右奇异向量，并进行去齐次化以恢复 $\mathbf{x}_n \in \mathbb{R}^3$ 。然后目标位置取质心 $\mathbf{p}_{\text{obj}} = \frac{1}{N} \sum_{n=1} \mathbf{x}_n$ ，这样可消

除逐点三角测量噪声。

B.2 阶段检测

一段原始 Aria 录制会交错包含主动操作和非操作片段——走向工作区、前置场景扫视（附录 B.1），以及任务结束后的后退。只有操作部分包含干净的手-物体动态，因此我们运行一个自动阶段检测步骤，将每段录制分割为若干运动模式，并仅保留用于训练的操作帧。


阶段分类。每一帧被分配到五种模式之一：(0) MANIP——演示者静止并主动操作场景；(1) FORWARD——线性前进；(2) ROTATE——原地头部/身体旋转（例如场景扫视）；(3) TRANSITION——相邻模式之间的短暂缓冲；(4) FINISHED——录制结束时持续保持最终静止。

分割信号与训练数据选择。相位由两条流计算：来自 Aria SLAM 的 6-DoF 头部轨迹（身体运动）以及来自手部跟踪器的 3D 手部轨迹（操作运动）。当头部线速度和角速度在连续 ≥ 15 帧中同时都降到 $v_{\text{stop}} = 0.03 \text{ m/s}$ 和 $w_{\text{stop}} = 0.15 \text{ rad/s}$ 以下时，某一帧进入 MANIP；ROTATE

需要 $\|\omega_{\text{head}}\| > 0.10\text{rad/s}$ 且 $\|\mathbf{v}_{\text{head}}\| < 0.08\text{ m/s}$ ；FORWARD 收集其余的高线速度帧；TRANSITION 在每次模式变化时填充一个 10 帧缓冲区；一旦末端停止持续 ≥ 30 帧，即判定为 FINISHED。我们还通过手部运动学对 MANIP 进行进一步精炼：若在 5 帧窗口内手部平均速度超过 0.15 m/s ，则将候选帧降级为 TRANSITION，从而将伸展/回缩动作从操作核心中裁切掉。随后训练流程只保留 MANIP (0) 和 FINISHED (4)，丢弃 FORWARD、ROTATE 和 TRANSITION，因此场景扫描、导航以及模式变化缓冲区都不会触达训练信号。

B.3 手到夹爪的转移

为了将人的视角视频当作机器人数据处理，每一帧的演示都必须携带一个末端执行器目标，而平行对夹机器人确实能够执行。然而人的手具有 21 个关节关键点，形态也与双指夹爪差异很大，因此原始手部姿态不能直接传递。我们因此通过一个短的运动优化流程，把手重定向到一个虚拟夹爪：即一个 6-DoF 的 SE(3) 位姿，再加上由少量在解剖学上相对稳定的关键点推导出的 1-DoF 抓取标量。



手部关键点提取。我们从 Aria MPS [7] 生成的 21 关键点手部骨架开始，该方法融合双目 SLAM 相机与设备端 IMU，从而在每一帧中恢复每个关键点在 SLAM 世界坐标系下的 3D 位置。对于

重定向，我们每只手只使用五个关键点（图 12）：手腕、拇指 MCP、拇指指尖、食指 MCP 和食指指尖。

运动优化。原始 MPS 关键点带有噪声，且偶尔会丢帧；直接将其输入到 SE(3) 构建中会产生抖动且容易翻转的轨迹。因此我们运行一个短的优化流程：（1）置信度掩码——丢弃任何其 MPS 置信度低于 0.8 的关键点，并丢弃检测片段少于连续 30 帧的段落，视为可能的幽灵检测；（2）间隙插值——将缺失的区间（ ≤ 10 帧）用位置的线性插值以及朝向的 SLERP 填充，使后续得到更平滑的稠密序列；（3）Savitzky-Golay 位置平滑——对五个重定向关键点应用一个窗口大小为 21、二阶多项式的 SG 滤波器，去除高频抖动，同时保留与操作相关的加速度；（4）EMA 朝向平滑——对夹爪坐标系的 X -轴和 Y -轴（下文定义）应用指数滑动平均，指数为 $\alpha_x = \alpha_y = 0.15$ ，每次更新后通过 Gram-Schmidt 重新正交归一，并在相邻帧之间强制符号一致性，避免不必要的 180° 翻转。

末端执行器位置。我们取拇指指尖与食指指尖的中点作为夹爪位置，这自然对应于平行对夹抓取的中心：

$$\mathbf{p}_{\text{ee}} = \frac{1}{2}(\mathbf{p}_{\text{thumb tip}} + \mathbf{p}_{\text{index tip}}). \quad (5)$$

末端执行器朝向。在捏握（pinch grasps）过程中选择既准确又稳定的朝向，是重定向（retargeting）中更微妙的部分；两种自然的替代方案都失败了。（i）原始腕部姿态：直接使用 MPS 的腕部朝向作为夹爪（gripper）坐标系是不准确的，因为人体解剖学的腕部坐标系并未与夹爪实际使用的拇指-食指动作轴对齐。（ii）腕部到指尖中点：将前向轴定义为腕部 $\rightarrow$ mid(拇指尖,食指尖)，将下颚（jaw）轴定义为拇指尖 $\rightarrow$ 食指尖。此方法在手张开时可行，但在抓握的瞬间会退化——两指尖几乎收敛到同一点，使下颚轴塌缩为接近零的向量，坐标系变得不可定义。我们改用来自 MCP 关节来构建夹爪坐标系，因为在完整捏握周期中，MCP 关节之间始终保持良好分离。写下 $\mathbf{p}_w$, $\mathbf{p}_{\text{tMCP}}$, $\mathbf{p}_{\text{iMCP}}$ 表示腕部、拇指-MCP 和食指-MCP 的位置，我们构造

$$\mathbf{x}_{\text{ee}} = \widehat{\mathbf{p}_{\text{iMCP}} - \mathbf{p}_{\text{tMCP}}}, \quad \mathbf{y}_{\text{ee}} = \tilde{\mathbf{y}} - (\tilde{\mathbf{y}}^\top \mathbf{x}_{\text{ee}}) \mathbf{x}_{\text{ee}}, \quad \mathbf{z}_{\text{ee}} = \mathbf{x}_{\text{ee}} \times \mathbf{y}_{\text{ee}}, \quad (6)$$

其中 $\tilde{\mathbf{y}} = \frac{1}{2}(\mathbf{p}_{\text{tMCP}} + \mathbf{p}_{\text{iMCP}}) - \mathbf{p}_w$ 为原始的腕部到 MCP 中点的向量, $\widehat{\cdot}$ 表示单位化 (unit normalization)。直观地, $\mathbf{y}_{\text{ee}}$ 是前向轴 (腕部 $\rightarrow$ MCP 中点), $\mathbf{x}_{\text{ee}}$ 是下颞开合轴 (拇指 MCP $\rightarrow$ 食指 MCP), 而 $\mathbf{z}_{\text{ee}}$ 是它们的正交补 (orthogonal complement)。旋转 $R_{\text{ee}} = [\mathbf{x}_{\text{ee}} \mid \mathbf{y}_{\text{ee}} \mid \mathbf{z}_{\text{ee}}] \in \text{SO}(3)$ 与式 (5) 中的位置 $\mathbf{p}_{\text{ee}}$ 共同给出末端执行器位姿 $\text{SE}(3) T_{\text{ee}}$ 。由于在捏握过程中这两个 MCP 从不彼此塌合, 因此这种构造在整个抓握/释放周期内数值上保持稳定。

夹爪开口 (Gripper aperture)。我们由拇指-食指指尖间距推导 1-DoF 的夹爪指令:

$$g = \text{clip}\left(\frac{\|\mathbf{p}_{\text{thumb tip}} - \mathbf{p}_{\text{index tip}}\| - d_{\min}}{d_{\max} - d_{\min}}, 0, 1\right), \quad (7)$$

其中 $d_{\min}$ 和 $d_{\max}$ 分别是按每位用户标定得到的闭合与完全打开的指尖距离。随后对归一化的 g 进行中值滤波 (median-filtered), 再通过一个短暂的抑制闪烁 (flicker-suppression) 步骤, 生成干净的开/合指令序列, 并在部署时进行二值化。

C 训练细节

C.1 流匹配策略

速度场与损失。我们训练一种条件流匹配 [33] 策略, 将高斯先验 $\mathbf{x}_0 \sim \mathcal{N}(0, I)$ 映射到沿线性路径 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1$ 的真实双手动作块 $\mathbf{x}_1 \in \mathbb{R}^{K \times D_a}$, 并使用流时间 $t \sim \mathcal{U}(0, 1)$ 。目标速度为恒定位移 $\mathbf{v}_{\text{target}} = \mathbf{x}_1 - \mathbf{x}_0$, 流匹配损失是在预测速度上计算的均方误差, 并按维度进行加权: 位置上 $w_p = 5$, 6D 旋转上 $w_r = 1$, 抓取 logit 上 $w_g = 10$ 。我们还支持一种最优传输匹配变体 (OT-CFM), 在每个小批量内先在噪声样本与动作样本之间求解匈牙利分配, 再计算损失, 从而产生更“直”的目标流; 由于我们在任务上未发现稳定的收益, 默认不启用。

网络。速度场 v_θ 是一个 6 层、8 头的 Transformer 解码器, 嵌入维度为 384, dropout 为 0.05。每个动作块 token 通过自注意力关注该块的其余部分, 并通过交叉注意力关注条件上下文。上下文由两条流构建: (i) RGB 帧, 使用 16×16 的 patch embedding 对 240×320 作为输入进行嵌入, 并通过一个小型 MLP 融合正弦时间嵌入; 以及 (ii) 状态 token, 即第 3.3 节所述的每实体 ICT token, 线性投影到 384 个通道。

辅助头。三个密集的辅助目标与速度场共享上下文编码器 (第 3.4 节)。物体动力学头预测被操控物体的 9 维未来位姿轨迹, 并使用 $0.5(w_p, w_r)$ 加权的 MSE 进行训练; 2D 视觉前瞻头通过浅层反卷积堆输出 3 个锚点的 $K \times 3 \times 2$ 归一化图像坐标, 损失权重为 $w_f = 20$; 时间一致性头预测提前 K 步的手部 tokens, 并使用按 $w_c \in [0.1, 1.0]$ 加权的掩码 MSE。三个目标均由感知流水线自动生成, 因此每次演示都能产生无需额外标注的密集多任务信号。

额外技巧。两个轻量的训练技巧进一步稳定从数分钟数据中的学习。区域注意力偏置图像交叉注意力指向当前正在进行的操控锚点: 给定锚点的二维图像投影 (u_0, v_0) , 我们将注意力 logits 乘以一个高斯聚光灯

$$w(u, v) = \exp\left(-\frac{(u - u_0)^2 + (v - v_0)^2}{2\sigma^2}\right), \quad (8)$$

其空间尺度 σ 是一个可学习参数, 从而在不进行硬裁剪的情况下, 柔和地将编码器聚焦到与任务相关的图像区域。状态噪声注入会在训练期间扰动每个手部 token, $\tilde{s}_t = s_t + \epsilon$ 使用 $\epsilon \sim \mathcal{N}(\mathbf{0}, \sum_s)$, 并分别对位置、6D 旋转和抓取通道设置独立的标准差, 这使得策略在部署时面对遇到的较小感知噪声时更鲁棒。

优化配方。我们使用 AdamW, 并以 10^{-4} 作为基础学习率, 采用带 200 步 warmup 的余弦衰减, 最小学习率比例为 0.05, batch size 为 32, 并训练 400 个 epoch。我们将梯度范数裁剪到 1.0, 使用 bfloat16 混合精度, 并在评估与部署时保留权重的指数移动平均, 其衰减系数为 0.999。

数据增强。为了从每个任务仅有 ~ 40 min 个人视频扩展有效的训练分布，我们在数据加载器中即时应用一组增强操作，并分为三类。(i) 对RGB流的图像增强。光度抖动 ($p = 0.8$) 会随机扰动亮度 (± 0.20)、对比度 (± 0.20) 和伽马 (± 0.15)，加入高斯像素噪声 ($\sigma = 0.02$)，可选地将帧转换为灰度 ($p = 0.1$)，并将HSV色相抖动 $\pm 10^\circ$ 、饱和度抖动 $[0.6, 1.4]$ 。随机调整大小的裁剪 ($p = 0.5$) 会在缩放 $[0.7, 1.0]$ 和宽高比 $[0.9, 1.1]$ 的范围内抽取子窗口，然后再缩放回网络输入大小。使用核大小为 3×3 的高斯模糊并以 $p = 0.15$ 进行，同时随机擦除 ($p = 0.5$) 会覆盖3-8个黑色遮挡补丁，每个补丁覆盖帧面积的5-20%。(ii) 动作-目标增强。我们在动作片段中对每个目标位姿进行加性扰动：平移加上高斯噪声- $\sigma_{\text{pos}} = 1$ mm，旋转加上高斯噪声- $\sigma_{\text{rot}} = 0.5^\circ$ ，然后计算流匹配损失；该过程通过标签中的小幅跟踪噪声来对速度场进行正则化。(iii) 时间增强。通过 $p = 0.5$ 我们应用子步插值：相邻的状态/动作帧以随机 $\alpha \in [0, 1]$ 进行线性混合，从而在不增加额外采集成本的情况下有效加密时间网格。

D 推理细节

D.1 机器人推理设置

除了零样本泛化研究（第4.3节）之外，主论文中的所有真实世界实验都采用如图13所示的单一推理设置：两台Trossen WidowX AI机械臂并排安装在同一工作台上，构成双臂平台，在无需任何硬件改动的情况下同时处理单臂和双臂任务。



图13：机器人推理设置。

每个任务之间。每台WidowX AI机械臂都是6自由度并联夹爪式操作器：在全行程范围内承载载荷为 ~ 1.5 kg，末端执行器重复性为 ± 1 mm。对于视觉输入，我们使用一台放置在工作空间上方的单个Intel RealSense D405进行俯视采集；其RGB流是HumanEgo所消耗的唯一观测。每台WidowX AI机械臂还配有内置腕部相机，但我们刻意不为HumanEgo使用它：与此相反，第四章第4.1节中的机器人遥操作ACT基线[28]会将腕部相机作为其标准观测接口的一部分来使用。

D.2 流匹配展开与控制

ODE rollout。在测试时，我们使用20步推理，将学习到的速度场与固定步长的欧拉求解器进行积分：从在策略加载时只抽取一次的噪声样本 $\mathbf{x}_0 \sim \mathcal{N}(0, I)$ 出发，依次迭代 $\mathbf{x}_{t+\Delta t} \leftarrow \mathbf{x}_t + v_\theta(\mathbf{x}_t, t, s_t)\Delta t$ 并用 $\Delta t = 1/20$ ，在一次前向重规划中得到一个包含 $K = 50$ -步的双手动作块。预测会按维度解包为每只手的位置、6D旋转和抓取logit；位置用数据集均值/方差反归一化，旋转通过对6D表示做“先归一化后Gram-Schmidt”的SO(3)投影后再使用，抓取结果通过sigmoid处理。

动作块切分与控制。控制器在每个周期 (10 Hz) 进行重规划，历史中最多保留一个预测，并且每个周期只执行一个动作。步幅为2会对动作块进行子采样，因此有效执行速率为5 Hz，同时提前25步的look-ahead偏移使控制器能在当前执行索引之前略微向前查询动作块，从而掩蔽规划延迟。对于抓取，我们使用任意时域 (any-over-horizon) 规则：只要当前动作块中任意一步预测的抓取概率超过0.6，夹爪就会闭合；可选的抓取锁存模式还能在第一次抓取事件发生后额外锁住夹爪闭合，以防止任务中途意外释放。

平滑与安全。为了掩盖预测的SE(3)序列中的小噪声，我们在将目标流式传给机械臂之前，对位置 ($\alpha = 0.5$) 做EMA，对旋转做四元数SLERP，并使用轨迹重叠融合（平滑参数12）来避免相邻动作块之间出现突兀的起停。最后，安全笼限制每个周期的目标位移：位置为 ≤ 0.08 m，旋转为 ≤ 0.02 rad，以防止突然的异常值；在我们的实验中，正常的rollout期间未观察到安全笼的触发/钳制。

E 额外实验分析

E.1 手部跟踪方法研究




图14：在Serve Bread上的手部跟踪对比（45次演示，~45k 帧）。上：平滑性——夹爪中点的逐帧抖动（平移与角度）以及所有21个关键点（越低越好，对数尺度）。下：与 Aria-MPS 的精度对比——经Procrustes对齐后的每个关键点形状误差，减去系统性帧偏移后的残余旋转误差，以及具有有效手部检测的帧比例。

设置。ICT以输入形式使用3D手部关键点，因此上游手部跟踪器的质量会直接影响策略能够学到什么。我们通过在Serve Bread上固定其他所有因素来隔离这种依赖——相同的45次演示（总计30分钟）、相同的HumanEgo架构、相同的训练流程；只改变负责生成动作标签的手部跟踪模块。我们比较了文献中主导设计选择的四种跟踪器，




Fig. 15: Hand Tracking Method Study.

术语：(1) Aria-MPS [7]，我们的默认方案，通过 Meta 的 MPS 流水线将两路宽视场单色 SLAM 相机与机载 IMU 融合，以恢复度量 3D 关键点——注意，中央 RGB 相机仅用于视频记录，不用于手部跟踪；(2) WiLoR [65]，一种 Transformer，每帧仅从一个 RGB 裁剪回归 MANO 参数；(3) HaMeR [66]，一种强大的单目 RGB 估计器，也预测 MANO 参数，但逐帧独立处理——此后已提出该类方法的时间和世界坐标系扩展 [67, 68]；(4) MediaPipe [69]，一种轻量级单目 RGB 流水线，其 3D 输出相对于根部，必须结合相机深度进行提升。除了这些仅视觉的跟踪器，我们还考察了通过多模态传感手套 [70] 或 6 轴 IMU 系统 [71] 采集的有仪器方案，但这些方案需要演示者配备专用硬件，超出了我们的零仪器采集设置。对于每个跟踪器，我们都重新运行数据预处理，从头训练 HumanEgo，并在 Serve Bread 上评估 40 次真实世界试验（图 15）。在图 14 中，Aria-MPS 被视为所有对齐类指标的参考。

结果。图 15 显示，随着我们从双目 Aria-MPS 转向单目跟踪器，真实世界成功率骤降至 95 → 45 → 32.5 → 0%，图 14 则解释了原因。我们强调四点观察。

双目深度对下游成功至关重要。将双目换成单目 RGB 的那一刻，真实世界成功率就从 95% (Aria-MPS) 降至至多 45% (WiLoR)。单目网络在深度轴上本质上存在尺度歧义，产生 5-11 厘米的系统性深度偏移，并直接传播到 ICT 参考系中，因此策略始终学不到一致的抓取。

平滑性和跟踪持续性——而非姿态精度本身——区分了幸存的基线。经过 Procrustes 对齐后，HaMeR 和 WiLoR 的逐关键点残差几乎相同 (1.4cm 对 1.4cm；两者都主要受共享的 MANO 归纳偏置支配)，MediaPipe 则仅略差一些 (2.2cm)。然而，WiLoR (45%) 明显优于 HaMeR (32.5%)。这一差距可由平滑性面板解释：WiLoR 的夹爪中点抖动比 HaMeR 低一个多数量级——其逐帧预测恰好更加时间稳定——且其检测率为 86.9%，而 MediaPipe 仅为 66.5%。抖动或间歇缺失的轨迹会向策略传递不连贯的动作标签。

MANO 先验是一把双刃剑。HaMeR 和 WiLoR 的逐关键点 Procrustes 残差几乎完全一致 (图 14 左下)：两个手部骨架上的彩色模式在视觉上难以区分。这并非巧合——两种网络都回归 MANO 姿态参数，并继承了相同的规范骨骼比例。共享的形状先验意味着它们的残余形状误差在构造上相关，而没有参数化约束的方法 (Aria-MPS、MediaPipe) 则会以不同方式偏离。这解释了为什么仅凭姿态精度很难预测下游策略成功。

MediaPipe 完全失败。真实世界成功率为 0%，检测率仅 66.5%，即使 ICT 表征吸收了一些噪声，MediaPipe 也无法产生连贯的动作标签。其 3D 输出相对于根部，必须借助相机深度进行提升，而这一提升会将手部厚度坍塌为 $\sim 7\text{ cm}$ (相较于 Aria 的 $\sim 16\text{ cm}$)，抹平了 ICT 所依赖的姿态信息。


综合这些结果，传递出一个清晰的实践信息：投资感知前端。一个更准确的手部跟踪器——尤其是能利用双目或学习到的深度的方案——是任何基于手部派生空间 token 的策略最具杠杆效应的升级。

E.2 人机联合训练研究

设置。数据效率研究 (第4.2节) 表明，在相同的总采集时间下，人类示范大约比机器人远程遥控操作 $3.75\times$ 更具样本效率。这里我们提出一个互补问题：当两种模态都可用时，最佳的混合比例是多少？我们将总采集时间固定为 30 min，并以 25 个百分点的步长改变来自 0% 的人类数据比例 (纯机器人远程遥控操作， ~ 45 个遥控操作回合) 到 100% (纯人类第一人称视频， ~ 45 个第一人称示范)。每个批次都按对应比例采样，因此策略在每一次梯度步骤中都能以预期比例同时看到两种模态。五种条件下的架构、优化器、调度和训练步数保持完全一致；只有数据混合比例发生变化。我们在每个条件下评估 40 次真实世界实验，任务为 Serve Bread。

结果。随着人类数据比例增加，真实世界中的成功率单调上升：

65 $\rightarrow$ 72.5 $\rightarrow$ 77.5 $\rightarrow$ 90 $\rightarrow$ 95%，在人类比例为 0/25/50/75/100% 时 (图16)。纯人类策略比纯机器人策略提高了 +30 个百分点——这一差距大于我们大多数基线之间的差距。我们提炼出两个主要发现。



哪怕只是一小部分人类数据也占据主导。

图16: 人机共同训练研究。仅用 25% 的机器人遥控操作数据替换为主体视角视频，成功率已从 65% 提升到 72.5% (+7.5 个百分点)，尽管在该条件下机器人数据的绝对量从 30 分钟下降到 22.5 分钟。朴素的“更多数据总是更好”观点会预测相反结果：更少的机器人数据应当会造成伤害。相反，策略得到改进，表明每增加一段机器人的分钟数所提供的信号，比每增加一段人的分钟数要更少。这复现了数据效率的结论 (第4.2节) 在

梯度步长的水平：相较于大量遥操作轨迹，策略更乐于从少量干净的第一人称视频中学习。

数据越人类，越好——不存在联合训练的“甜点”。在四种转移设置中，曲线都只会上升，而纯人类策略就是全局最大值。我们没有找到“甜点”，即引入机器人数据能超过仅人类条件——事实上，75/25 (90%) 已经比 100/0 (95%) 低 5 个百分点；因此，即使再加入 7.5 min 的机器人远程操控，也会主动削弱一个 22.5 min 的人类数据集。我们将其归因于第 4.2 节（图 6）中记录的人类示范具有更高的“每分钟信息密度”：人类视频具有更高的信噪比，轨迹平滑度高一个数量级，几乎为零的空闲时间，并且空间覆盖范围比机器人远程操控更广。在固定的计算与时间预算下，策略最好做法是将每一分钟都用于人类数据。再结合 ICT 的体态不变性，这意味着部署 HumanEgo 的从业者根本不应进行机器人远程操控——同样的预算下，收集到的以第一人称为中心的人类视频所带来的策略严格更好。

E.3 参考系研究

在 ICT 中，选择参考坐标系是一个关键的设计决策。我们比较两种策略：(1) 锚定坐标系，在该坐标系中，轨迹中每个实体的姿态以及动作轨迹都相对于轨迹中首先被抓取的那个物体来表达；(2) 相机坐标系（用于我们的主要实验），在该坐标系中，所有姿态都在相机的坐标系中表达。两种表示之间存在明确的权衡，其平衡会随着训练数据量的变化而转移（图 17）。




Fig. 17: Coordinate Frame Study.

低数据场景：锚定坐标系胜出。训练示范很少时，用锚定坐标系来表征场景会显著加速策略学习。因为锚定坐标系将空间推理绑定到与任务相关的物体上，而不是相机上，模型只需更少的示范就能恢复操作的基本几何关系——尤其是接触瞬间手与目标物体之间的相对位姿。这个抓取先验恰恰是许多模仿学习场景中限制样本效率的瓶颈，而锚定坐标系提供了强大的归纳偏置来绕过它。结果是在只有少量轨迹可用时，抓取成功率和下游任务完成率都明显更高。

大数据规模：相机坐标系开始追上并超越锚点坐标系。随着训练数据不断增加，模型拥有足够的信号，能够直接从相机坐标系观测中恢复出相同的几何关系。在这一点上，相机坐标系变得更可靠，原因有二：(i) 它直接基于原始传感器，不受上游感知误差污染；而 (ii) 锚点坐标系继承了来自目标检测和姿态估计模块（Grounding DINO、SAM2、Orient-Anything）的噪声，这些误差会直接扰动每一个变换后的坐标。经验上，在数据足够时，相机坐标系版本在分布内评估上与锚点坐标系版本持平，并略优于后者，因为锚点坐标系策略最终受限于其上游物体位姿估计的准确性。

锚点坐标系的持久优势：相机位姿不变性。尽管在原始成功率上两者在渐近意义上趋于一致（或略逊一筹），锚点坐标系仍保有相机坐标系无法提供的一项特性：部署时对相机放置的鲁棒不变性。由于每个坐标都相对于物体来表达，相机的绝对位置和朝向并不重要——该策略可在相机安装于任意合理角度、高度或距离时部署，并表现完全一致。相比之下，相机坐标系策略与特定视角分布绑定，一旦相机位置改变性能就会明显下降，迫使每次新的安装都要重新采集数据或微调。

F 超参数

表1汇总了主文和附录中出现的所有超参数值，并按管线阶段分组。除非另有明确说明，四个任务、所有训练运行以及所有真实世界试验均使用同一组数值。

表1: HumanEgo 使用的全部超参数。除非另有说明，四个任务共享相同数值。

Parameter	Value
<i>Data Collection (App. A.1, App. A.2)</i>	
Demonstrations per task	60
Total human-video time per task	40 min
RGB stream rate / resolution	30 fps / 2 MP
SLAM cameras: count, rate, resolution	2, 30 fps, VGA
Eye-tracking cameras: count, rate, resolution	2, 10 fps, QVGA
IMU rates	1000 Hz, 800 Hz
Pre-episode scene-sweep duration	1–2 s
Scene-sweep frame count	30–60
<i>Phase Detection (App. B.2)</i>	
Head linear-speed stop threshold v_{stop}	0.03 m/s
Head angular-speed stop threshold w_{stop}	0.15 rad/s
Minimum stop-hold duration	15 frames
Rotate trigger w_{rot}	0.10 rad/s
Rotate max linear speed $v_{\text{rot,max}}$	0.08 m/s
Transition buffer	10 frames
Hand-velocity demotion threshold v_{hand}	0.15 m/s
Hand-velocity averaging window	5 frames
Finished-stop length	30 frames
<i>Hand-to-Gripper Retargeting (App. B.3)</i>	
Retarget keypoints per hand	5
MPS confidence threshold	0.8
Minimum detection segment	30 frames
Max gap for interpolation	10 frames
Savitzky–Golay window	21 frames
Savitzky–Golay polynomial order	2
EMA smoothing factor $\alpha_x = \alpha_y$	0.15
<i>Policy Network (App. C.1)</i>	
Transformer layers	6
Transformer attention heads	8
Transformer embedding dim	384
Dropout	0.05
RGB patch size	16×16
RGB input resolution	240×320
ICT token dim	29
Prediction horizon K	50
<i>Losses (App. C.1)</i>	
Position weight w_p	5
Rotation weight w_r	1
Grasp weight w_g	10
Object-dynamics weight (pos / rot)	$0.5 w_p / 0.5 w_r$
Visual-foresight weight w_f	20
Temporal-consistency weight w_c	[0.1, 1.0]
<i>Optimization (App. C.1)</i>	
Optimizer	AdamW
Base learning rate	1×10^{-4}
Warmup steps	200
Min-LR ratio	0.05
Batch size	32
Epochs	400

续见下页

表1 - 接前页

Parameter	Value
Gradient-norm clip	1.0
EMA decay	0.999
<i>Data Augmentation (App. C.1)</i>	
Photometric jitter probability	0.8
Brightness / contrast delta	$\pm 0.20 / \pm 0.20$
Gamma delta	± 0.15
Pixel noise σ	0.02
Grayscale probability	0.1
HSV hue jitter	± 10
HSV saturation range	[0.6, 1.4]
Random resized crop probability	0.5
Scale range	[0.7, 1.0]
Aspect-ratio range	[0.9, 1.1]
Gaussian blur probability	0.15
Kernel size	3×3
Random erasing probability	0.5
Number of holes	3–8
Per-hole area	5–20%
Target position noise σ_{pos}	1 mm
Target rotation noise σ_{rot}	0.5°
Sub-step interpolation probability	0.5
<i>Hardware (App. D.1)</i>	
Robot arms	2× Trossen WidowX AI
WidowX AI DoF	6
WidowX AI payload at full reach	~ 1.5 kg
WidowX AI end-effector repeatability	± 1 mm
Inference RGB camera	Intel RealSense D405 (top-mounted)
<i>Inference (App. D.2)</i>	
Euler ODE steps	20
Step size Δt	1/20
Executed action-chunk length	$K = 50$
Control-loop frequency	10 Hz
Action-step stride	2
Effective executed rate	5 Hz
Look-ahead offset	25 steps
Grasp probability threshold	0.6
Position smoothing EMA α	0.5
Rotation smoothing	quaternion SLERP
Trajectory-overlap smoothing parameter	12
Safety cage: max position step	0.08 m
Safety cage: max rotation step	0.02 rad
<i>Robot Teleoperation for ACT Baseline</i>	
Teleop control frequency (leader $\rightarrow$ follower)	200 Hz
Teleop recording frequency	30 Hz
Leader $\rightarrow$ follower EMA α	0.5
Top camera resolution	640×480
Wrist camera resolution	320×240
Action space	7-DoF joint positions
Proprioception dim	7
<i>ACT Baseline Training</i>	
Visual backbone	ResNet-18 (pretrained)
Embedding dim	256
Attention heads	8
Encoder / decoder layers	4 / 1
Feed-forward dim	2048
CVAE latent dim	32
Dropout	0.1
Prediction horizon K	50

续见下页

表1 - 接前页

Parameter	Value
Image input resolution	240×320
Batch size	24
Epochs	400
Base learning rate	1×10^{-4}
Weight decay	1×10^{-2}
Warmup steps	500
EMA decay	0.999
Action L1 weight w_{pos}	5.0
CVAE KL loss weight (annealed to)	10.0